POLSKO-JAPOŃSKA AKADEMIA TECHNIK KOMPUTEROWYCH

SYLABUS PRZEDMIOTU

Nazwa przedmiotu:	**Wprowadzenie do machine learning**
Kod przedmiotu:	IML
Kierunek / Profil:	Informatyka / praktyczny
Tryb studiów:	niestacjonarny
Rok / Semestr:	3 / 6
Charakter:	obowiązkowy
Odpowiedzialny:	dr inż. Paweł Syty
Wersja z dnia:	19.02.2026

1. Godziny zajęć i punkty ECTS

Wykłady	Ćwiczenia	Laboratori	Z prowadzącym	Praca własna	Łącznie	ECTS
16 h	—	16 h	32 h	93 h	125 h	**5**

2. Forma zajęć

Forma zajęć	Sposób zaliczenia
Laboratorium	Zaliczenie z oceną
Wykład	Egzamin z oceną

3. Cel dydaktyczny

Celem przedmiotu jest zaznajomienie studentów z podstawowymi zagadnieniami uczenia maszynowego (w tym elementami uczenia głębokiego), głównie z wykorzystaniem sieci neuronowych (w tym sieci splotowych), a także z metodami programowania wybranych metod oraz praktycznym wykorzystaniem gotowych narzędzi.

Wersja w języku angielskim (English version)

The aim of the course is to familiarize students with the basic issues of machine learning (including elements of deep learning), mainly using neural networks (including convolutional neural networks), as well as with methods for programming selected techniques and the practical use of ready-made tools.

4. Treści programowe

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
1. Historia i definicja uczenia maszynowego. Omówienie zastosowań uczenia maszynowego. Podział metod uczenia maszynowego. Rola danych i ich jakości w uczeniu maszynowym. Przygotowywanie danych do procesu uczenia. Wstęp do języka Python.		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
2. Wiedza niedoskonała w uczeniu maszynowym. Metody radzenia sobie z niedoskonałością wiedzy. Wnioskowanie bayesowskie. Logika rozmyta.		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
3. Podstawy biologiczne sztucznych sieci neuronowych. Układ nerwowy zwierząt i człowieka – podział i funkcje. Odbiór i przetwarzanie bodźców przez mózg. Neuron – budowa, systematyka. Przejawy życiowe neuronów. Pamięć. Dyskusja możliwości i ograniczeń związanych z odwzorowywaniem układów biologicz-		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
4. Historia i podstawy sieci neuronowych. Podstawowy model komórki nerwowej – perceptron prosty i jego właściwości. Perceptron prosty jako uogólnienie regresji liniowej. Podstawowe metody uczenia perceptronu. Ograniczenia pojedynczego perceptronu. Łączenie perceptronów w większe struktury.		
Podstawowa klasy-		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
5. Sieci jednokierunkowe jednowarstwowe. Budowa, metody uczenia, zastosowania, ograniczenia. Mapa wag. Hiperparametry. Metryki. Kodowanie danych.		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
6. Sieci jednokierunkowe wielowarstwowe. Budowa, metody uczenia, zastosowania, ograniczenia. Więcej o metodach uczenia sieci – metoda propagacji wstecznej, metoda momentum (w tym metoda Nesterova). Omówienie wybranych optymalizatorów (SGD, RMSprop, Adam). Inicjalizacja modelu. Funkcje aktywacji.		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
7. Zdolność uogólniania sieci neuronowej. Miary zdolności uogólniania. Twierdzenie Kołmogorowa. Zbiór uczący (treningowy), walidujący i testowy. Przeuczenie i niedouczenie sieci. Metody regularyzacji. Dobór optymalnej architektury sieci. Proces redukcji wymiaru sieci. Warstwy Dropout.		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
8. Sieci splotowe. Budowa, metody uczenia, zastosowania, ograniczenia. Operacja splotu (konwolucja). Warstwy łączące (pooling). Filtry. Biblioteka OpenCV. Metody i architektury sieci neuronowych do rozpoznawania obrazów. Sieci typu Lenet, VGGNet. Klasyfikacja wieloetykietowa. Augmentacja danych.		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
9. Sieci autoasocjacyjne. Transfer learning. Walidacja krzyżowa. Elementy wyjaśnialnej sztucznej inteligencji.		
10. Sieci rekurencyjne. Budowa, metody uczenia, zastosowania, ograniczenia. Pamięci asocjacyjne. Komórki LSTM i GRU.		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
11. Strategie gier dwuosobowych. Algorytm MINIMAX. Funkcja heurystyczna. Przycinanie alfabeta. Idea self-play.		
12. Automaty komórkowe ze szczególnym uwzględnieniem ich zastosowania w uczeniu maszynowym.		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
13. Pozostałe metody uczenia maszynowego: k-najbliższych sąsiadów, maszyna wektorów nośnych (SVM), drzewo decyzyjne, las losowy, algorytmy ewolucyjne, liniowe modele mieszane. Metody zespołowe (ensemble).		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
14. Elementy uczenia nienadzorowanego. Analiza skupień. Algorytm centroidów (k-means). Analiza szeregów czasowych. Algorytm k-shape i DTW (Dynamic Time Warping).		
15. Elementy języka Prolog. Zapis predykatów. Wnioskowanie wstecz i w przód.		

Nr zaj.	**Wykład**	**Ćwiczenia / Laboratorium / Pracownia**
// A. lista dotychczas zaproponowanych metod dydaktycznych; można zaproponować inne.		
Wykład:		
wykład		
wykład konwersatoryjny (z elementami dyskusji)		
wykład z prezentacją multimedialną		
wykład z prezentacją oprogramowania		
warsztaty		
Ćwiczenia / Laboratorium/Lektorat:		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
analiza tekstów z dyskusją		
metoda projektów (projekt praktyczny)		
praca w grupach		
dyskusja		
rozwiązywanie zadań		
burza mózgów		
mind map		
puzzle learning		
studia przypadków z bazy studiów przypadków opracowanych przez firmy MŚP lub będące efektem staży		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
praca grupowa nad projektem z wykorzystaniem nowoczesnych technik informatycznych		
warsztaty		
// B. lista dotychczas zaproponowanych metod weryfikacji; można zaproponować inne.		
sprawdziany wstępne „wejściówki”		
kolokwium		
kolokwium końcowe		
egzamin pisemny		
egzamin pisemny - test wyboru		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
egzamin pisemny - tekst z lukami		
egzamin pisemny z zadaniami problemowymi		
egzamin pisemny ze studium przypadku		
egzamin ustny		
końcowe sprawozdanie z pracy w zespole		
prezentacja samodzielnej pracy semestralnej		
prezentacja elementu zespołowej pracy semestralnej		
prezentacja projektu i dokumentacji		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
prezentacja mini-projektu		
obrona projektu		
rezultaty gry strategicznej		
ocena pracy podczas ćwiczenia		
raport z wykonanego zadania		
ocena sporządzonego dokumentu		
ocena sporządzonego oprogramowania		
wskazanie źródeł użytych materiałów		
kwestionariusz wywiadu		
sprawozdanie z rozmowy		
zapisanie na ścieżkę certyfikacyjną		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
//C. ECTS sposób obliczania		
1 punkt ECTS przyznawany jest za 25-30 godzin pracy studenta. W obliczanie punktów ECTS włącza się:		
liczbę godzin poszczególnych przedmiotów w danym semestrze;		

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
czas, jaki student poświęcił na indywidualną naukę (w tym przygotowanie do zajęć, zbieranie materiałów czy pisanie prac zaliczeniowych);		
czas, jaki student poświęcił na przygotowanie do egzaminu i zaliczenie danego przedmiotu;		
liczbę godzin praktyk studenckich.		

5. Przedmiotowe efekty uczenia się

Wiedza

- Student zna i rozumie zaawansowane pojęcia probabilistyki i statystyki: rozkłady prawdopodobieństwa, estymację, testy hipotez i ich zastosowanie w uczeniu maszynowym. [K_W12]
- Student zna i rozumie zasady działania i zastosowania algorytmów uczenia maszynowego: regresja, klasyfikacja (SVM, drzewa decyzyjne, lasy losowe), klasteryzacja, redukcja wymiarowości (PCA) i metody ewaluacji modeli. [K_W12]
- Student zna i rozumie zaawansowane pojęcia w zakresie sztucznej inteligencji: głębokie sieci neuronowe (CNN, RNN, Transformer), transfer learning i zasady odpowiedzialnej AI. [K_W22]

Umiejętności

- Student potrafi zastosować aparat matematyczny (rachunek różniczkowy, algebrę liniową, statystykę) do implementacji i analizy algorytmów uczenia maszynowego w Pythonie (scikit-learn, PyTorch/TensorFlow). [K_U07]
- Student potrafi zdiagnozować problem z obszaru sztucznej inteligencji, zaprojektować pipeline danych, wytrenować, ocenić i zoptymalizować model ML/DL na danych rzeczywistych. [K_U29]

Kompetencje społeczne

- Student jest gotów do zastosowania sztucznej inteligencji na rzecz rozwiązywania problemów naukowych i społecznych z uwzględnieniem zasad etycznej AI. [K_K01]
- Student jest gotów do samodzielnego śledzenia postępów w dziedzinie ML/AI i adaptowania nowych metod w praktyce inżynierskiej. [K_K03]

6. Kryteria oceny

- Brak danych.

7. Metody dydaktyczne

Wykład, laboratoria, praca własna studenta.

8. Literatura

Podstawowa:

- Daniel T. Larose „Metody i modele eksploracji danych”, PWN 2022

- Aurélien Géron, „Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow”, Helion 2020
- Robert Johansson „Matematyczny Python. Obliczenia naukowe i analiza danych z użyciem NumPy, SciPy i Matplotlib”, Helion 2021
- Sebastian Raschka, Vahid Mirjalili „Python. Machine learning i deep learning. Biblioteki scikit-learn i TensorFlow 2”, Helion 2021
- Aileen Nielsen, „Szeregi czasowe. Praktyczna analiza i predykcja z wykorzystaniem statystyki i uczenia maszynowego”, Helion 2020

Uzupełniająca:

- Joel Grus, „Data science od podstaw. Analiza danych w Pythonie”, Helion 2020
- Dokumentacja pakietów Keras i Tensorflow