POLSKO-JAPOŃSKA AKADEMIA TECHNIK KOMPUTEROWYCH

SYLABUS PRZEDMIOTU

Nazwa przedmiotu:	**Wprowadzenie do machine learning**
Kod przedmiotu:	IML
Kierunek / Profil:	Informatyka / praktyczny
Tryb studiów:	stacjonarny
Rok / Semestr:	3 / 5
Charakter:	obowiązkowy
Odpowiedzialny:	dr inż. Paweł Syty
Wersja z dnia:	08.03.2026

1. Godziny zajęć i punkty ECTS

Wykłady	Ćwiczenia	Laboratori	Z prowadzącym	Praca własna	Łącznie	ECTS
30 h	30 h	—	60 h	65 h	125 h	**5**

Zadania do samodzielnej realizacji: Samodzielne zadania programistyczne z machine learning; implementacja i testowanie modeli predykcyjnych; analiza wyników i dostrajanie hiperparametrów.

2. Forma zajęć

Forma zajęć	Sposób zaliczenia
Wykład	Egzamin
Ćwiczenia	Zaliczenie z oceną

3. Cel dydaktyczny

Celem przedmiotu jest zaznajomienie studentów z podstawowymi zagadnieniami uczenia maszynowego (w tym elementami uczenia głębokiego), głównie z wykorzystaniem sieci

neuronowych (w tym sieci splotowych), a także z metodami programowania wybranych metod oraz praktycznym wykorzystaniem gotowych narzędzi.

Wersja w języku angielskim (English version)

The aim of the course is to familiarize students with the basic issues of machine learning (including elements of deep learning), mainly using neural networks (including convolutional neural networks), as well as with methods for programming selected techniques and the practical use of ready-made tools.

4. Przedmioty wprowadzające

Przedmiot	Wymagane zagadnienia
Narzędzia Sztucznej Inteligencji	—

5. Treści programowe

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
1.	1. Historia i definicja uczenia maszynowego. Omówienie zastosowań uczenia maszynowego. Podział metod uczenia maszynowego. Rola danych i ich jakości w uczeniu maszynowym. Przygotowywanie danych do procesu uczenia. Wstęp do języka Python.	
2.	2. Wiedza niedoskonała w uczeniu maszynowym. Metody radzenia sobie z niedoskonałością wiedzy. Wnioskowanie bayesowskie. Logika rozmyta.	
3.	3. Podstawy biologiczne sztucznych sieci neuronowych. Układ nerwowy zwierząt i człowieka – podział i funkcje. Odbiór i przetwarzanie bodźców przez mózg. Neuron – budowa, systematyka. Przejawy życiowe neuronów. Pamięć. Dyskusja możliwości i ograniczeń związanych z odwzorowywaniem układów biologicznych w postaci sztucznych systemów.	

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
4.	4. Historia i podstawy sieci neuronowych. Podstawowy model komórki nerwowej – perceptron prosty i jego właściwości. Perceptron prosty jako uogólnienie regresji liniowej. Podstawowe metody uczenia perceptronu. Ograniczenia pojedynczego perceptronu. Łączenie perceptronów w większe struktury. Podstawowa klasyfikacja architektur sztucznych sieci neuronowych. Wstępna klasyfikacja zastosowań sieci neuronowych. Cechy sztucznych sieci neuronowych predestynujące je do zastosowań we współczesnym świecie.	
5.	5. Sieci jednokierunkowe jednowarstwowe. Budowa, metody uczenia, zastosowania, ograniczenia. Mapa wag. Hiperparametry. Metryki. Kodowanie danych.	
6.	6. Sieci jednokierunkowe wielowarstwowe. Budowa, metody uczenia, zastosowania, ograniczenia. Więcej o metodach uczenia sieci – metoda propagacji wstecznej, metoda momentum (w tym metoda Nesterova). Omówienie wybranych optymalizatorów (SGD, RMSprop, Adam). Inicjalizacja modelu. Funkcje aktywacji.	
7.	7. Zdolność uogólniania sieci neuronowej. Miary zdolności uogólniania. Twierdzenie Kołmogorowa. Zbiór uczący (treningowy), walidujący i testowy. Przeuczenie i niedouczenie sieci. Metody regularyzacji. Dobór optymalnej architektury sieci. Proces redukcji wymiaru sieci. Warstwy Dropout.	

Nr zaj.	Wykład	Ćwiczenia / Laboratorium / Pracownia
8.	8. Sieci splotowe. Budowa, metody uczenia, zastosowania, ograniczenia. Operacja splotu (konwolucja). Warstwy łączące (pooling). Filtry. Biblioteka OpenCV. Metody i architektury sieci neuronowych do rozpoznawania obrazów. Sieci typu Lenet, VGGNet. Klasyfikacja wieloetykietowa. Augmentacja danych.	
9.	9. Sieci autoasocjacyjne. Transfer learning. Walidacja krzyżowa. Elementy wyjaśnialnej sztucznej inteligencji.	
10.	10. Sieci rekurencyjne. Budowa, metody uczenia, zastosowania, ograniczenia. Pamięci asocjacyjne. Komórki LSTM i GRU.	
11.	11. Strategie gier dwuosobowych. Algorytm MINIMAX. Funkcja heurystyczna. Przycinanie alfa-beta. Idea self-play.	
12.	12. Automaty komórkowe ze szczególnym uwzględnieniem ich zastosowania w uczeniu maszynowym.	
13.	13. Pozostałe metody uczenia maszynowego: k-najbliższych sąsiadów, maszyna wektorów nośnych (SVM), drzewo decyzyjne, las losowy, algorytmy ewolucyjne, liniowe modele mieszane. Metody zespołowe (ensemble).	
14.	14. Elementy uczenia nienadzorowanego. Analiza skupień. Algorytm centroidów (k-means). Analiza szeregów czasowych. Algorytm k-shape i DTW (Dynamic Time Warping).	
15.	15. Elementy języka Prolog. Zapis predykatów. Wnioskowanie wstecz i w przód.	

6. Przedmiotowe efekty uczenia się

Wiedza

- Student zna i rozumie zaawansowane pojęcia probabilistyki i statystyki: rozkłady prawdopodobieństwa, estymację, testy hipotez i ich zastosowanie w uczeniu maszynowym. [K_W12]
- Student zna i rozumie zasady działania i zastosowania algorytmów uczenia maszynowego: regresja, klasyfikacja (SVM, drzewa decyzyjne, lasy losowe), klasteryzacja, redukcja wymiarowości (PCA) i metody ewaluacji modeli. [K_W12]
- Student zna i rozumie zaawansowane pojęcia w zakresie sztucznej inteligencji: głębokie sieci neuronowe (CNN, RNN, Transformer), transfer learning i zasady odpowiedzialnej AI. [K_W22]

Umiejętności

- Student potrafi zastosować aparat matematyczny (rachunek różniczkowy, algebrę liniową, statystykę) do implementacji i analizy algorytmów uczenia maszynowego w Pythonie (scikit-learn, PyTorch/TensorFlow). [K_U07]
- Student potrafi zdiagnozować problem z obszaru sztucznej inteligencji, zaprojektować pipeline danych, wytrenować, ocenić i zoptymalizować model ML/DL na danych rzeczywistych. [K_U29]

Kompetencje społeczne

- Student jest gotów do zastosowania sztucznej inteligencji na rzecz rozwiązywania problemów naukowych i społecznych z uwzględnieniem zasad etycznej AI. [K_K01]
- Student jest gotów do samodzielnego śledzenia postępów w dziedzinie ML/AI i adaptowania nowych metod w praktyce inżynierskiej. [K_K03]

7. Kryteria oceny

Wykład:

- egzamin pisemny

Ćwiczenia / Laboratorium:

- ocena sporządzonego oprogramowania
- ocena pracy podczas ćwiczenia

8. Metody dydaktyczne

Wykład:

- wykład z prezentacją multimedialną
- wykład z prezentacją oprogramowania

Ćwiczenia / Laboratorium:

- rozwiązywanie zadań
- studia przypadków z bazy studiów przypadków opracowanych przez firmy MŚP lub będące efektem staży
- warsztaty

9. Literatura

Podstawowa:

- Daniel T. Larose „Metody i modele eksploracji danych", PWN 2022
- Aurélien Géron, „Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow", Helion 2020
- Robert Johansson „Matematyczny Python. Obliczenia naukowe i analiza danych z użyciem NumPy, SciPy i Matplotlib", Helion 2021
- Sebastian Raschka, Vahid Mirjalili „Python. Machine learning i deep learning. Biblioteki scikit-learn i TensorFlow 2", Helion 2021
- Aileen Nielsen, „Szeregi czasowe. Praktyczna analiza i predykcja z wykorzystaniem statystyki i uczenia maszynowego", Helion 2020

Uzupełniająca:

- Joel Grus, „Data science od podstaw. Analiza danych w Pythonie", Helion 2020
- Dokumentacja pakietów Keras i Tensorflow