POLSKO-JAPOŃSKA AKADEMIA TECHNIK KOMPUTEROWYCH

SYLABUS PRZEDMIOTU

Nazwa przedmiotu:	**Wprowadzenie do machine learning**
Kod przedmiotu:	IML
Kierunek / Profil:	Informatyka / praktyczny
Tryb studiów:	stacjonarny
Rok / Semestr:	3 / 5
Charakter:	obowiązkowy
Odpowiedzialny:	dr inż. Paweł Syty
Wersja z dnia:	08.03.2026

1. Godziny zajęć i punkty ECTS

Wykłady	Ćwiczenia	Laboratori	Z prowadzącym	Praca własna	Łącznie	ECTS
30 h	30 h	—	60 h	65 h	125 h	**5**

2. Forma zajęć

Forma zajęć	Sposób zaliczenia
Wykład	Egzamin
Ćwiczenia	Zaliczenie z oceną

3. Cel dydaktyczny

Celem przedmiotu jest zaznajomienie studentów z podstawowymi zagadnieniami uczenia maszynowego (w tym elementami uczenia głębokiego), głównie z wykorzystaniem sieci neuronowych (w tym sieci splotowych), a także z metodami programowania wybranych metod oraz praktycznym wykorzystaniem gotowych narzędzi.

4. Przedmioty wprowadzające

Przedmiot	Wymagane zagadnienia
Narzędzia Sztucznej Inteligencji	—

5. Treści programowe

1. 'nr_zajec': 1, 'wyklad': '1. Historia i definicja uczenia maszynowego. Omówienie zastosowań uczenia maszynowego. Podział metod uczenia maszynowego. Rola danych i ich jakości w uczeniu maszynowym. Przygotowywanie danych do procesu uczenia. Wstęp do języka Python.', 'cwiczenia': ''
2. 'nr_zajec': 2, 'wyklad': '2. Wiedza niedoskonała w uczeniu maszynowym. Metody radzenia sobie z niedoskonałością wiedzy. Wnioskowanie bayesowskie. Logika rozmyta.', 'cwiczenia': ''
3. 'nr_zajec': 3, 'wyklad': '3. Podstawy biologiczne sztucznych sieci neuronowych. Układ nerwowy zwierząt i człowieka – podział i funkcje. Odbiór i przetwarzanie bodźców przez mózg. Neuron – budowa, systematyka. Przejawy życiowe neuronów. Pamięć. Dyskusja możliwości i ograniczeń związanych z odwzorowywaniem układów biologicznych w postaci sztucznych systemów.', 'cwiczenia': ''
4. 'nr_zajec': 4, 'wyklad': '4. Historia i podstawy sieci neuronowych. Podstawowy model komórki nerwowej – perceptron prosty i jego właściwości. Perceptron prosty jako uogólnienie regresji liniowej. Podstawowe metody uczenia perceptronu. Ograniczenia pojedynczego perceptronu. Łączenie perceptronów w większe struktury. Podstawowa klasyfikacja architektur sztucznych sieci neuronowych. Wstępna klasyfikacja zastosowań sieci neuronowych. Cechy sztucznych sieci neuronowych predestynujące je do zastosowań we współczesnym świecie.', 'cwiczenia': ''
5. 'nr_zajec': 5, 'wyklad': '5. Sieci jednokierunkowe jednowarstwowe. Budowa, metody uczenia, zastosowania, ograniczenia. Mapa wag. Hiperparametry. Metryki. Kodowanie danych.', 'cwiczenia': ''
6. 'nr_zajec': 6, 'wyklad': '6. Sieci jednokierunkowe wielowarstwowe. Budowa, metody uczenia, zastosowania, ograniczenia. Więcej o metodach uczenia sieci – metoda propagacji wstecznej, metoda momentum (w tym metoda Nesterova). Omówienie wybranych optymalizatorów (SGD, RMSprop, Adam). Inicjalizacja modelu. Funkcje aktywacji.', 'cwiczenia': ''
7. 'nr_zajec': 7, 'wyklad': '7. Zdolność uogólniania sieci neuronowej. Miary zdolności uogólniania. Twierdzenie Kołmogorowa. Zbiór uczący (treningowy), walidujący i testowy. Przeuczenie i niedouczenie sieci. Metody regularyzacji. Dobór optymalnej architektury sieci. Proces redukcji wymiaru sieci. Warstwy Dropout.', 'cwiczenia': ''
8. 'nr_zajec': 8, 'wyklad': '8. Sieci splotowe. Budowa, metody uczenia, zastosowania, ograniczenia. Operacja splotu (konwolucja). Warstwy łączące (pooling). Filtry. Biblioteka OpenCV. Metody i architektury sieci neuronowych do rozpoznawania obrazów. Sieci typu Lenet, VGGNet. Klasyfikacja wieloetykietowa. Augmentacja danych.', 'cwiczenia': ''

9. 'nr_zajec': 9, 'wyklad': '9. Sieci autoasocjacyjne. Transfer learning. Walidacja krzyżowa. Elementy wyjaśnialnej sztucznej inteligencji.', 'cwiczenia': ''
10. 'nr_zajec': 10, 'wyklad': '10. Sieci rekurencyjne. Budowa, metody uczenia, zastosowania, ograniczenia. Pamięci asocjacyjne. Komórki LSTM i GRU.', 'cwiczenia': ''
11. 'nr_zajec': 11, 'wyklad': '11. Strategie gier dwuosobowych. Algorytm MINIMAX. Funkcja heurystyczna. Przycinanie alfa-beta. Idea self-play.', 'cwiczenia': ''
12. 'nr_zajec': 12, 'wyklad': '12. Automaty komórkowe ze szczególnym uwzględnieniem ich zastosowania w uczeniu maszynowym.', 'cwiczenia': ''
13. 'nr_zajec': 13, 'wyklad': '13. Pozostałe metody uczenia maszynowego: k-najbliższych sąsiadów, maszyna wektorów nośnych (SVM), drzewo decyzyjne, las losowy, algorytmy ewolucyjne, liniowe modele mieszane. Metody zespołowe (ensemble).', 'cwiczenia': ''
14. 'nr_zajec': 14, 'wyklad': '14. Elementy uczenia nienadzorowanego. Analiza skupień. Algorytm centroidów (k-means). Analiza szeregów czasowych. Algorytm k-shape i DTW (Dynamic Time Warping).', 'cwiczenia': ''
15. 'nr_zajec': 15, 'wyklad': '15. Elementy języka Prolog. Zapis predykatów. Wnioskowanie wstecz i w przód.', 'cwiczenia': ''

6. Efekty kształcenia

Wiedza

- Student zna i rozumie zaawansowane pojęcia probabilistyki i statystyki: rozkłady prawdopodobieństwa, estymację, testy hipotez i ich zastosowanie w uczeniu maszynowym. [K_W12]
- Student zna i rozumie zasady działania i zastosowania algorytmów uczenia maszynowego: regresja, klasyfikacja (SVM, drzewa decyzyjne, lasy losowe), klasteryzacja, redukcja wymiarowości (PCA) i metody ewaluacji modeli. [K_W12]
- Student zna i rozumie zaawansowane pojęcia w zakresie sztucznej inteligencji: głębokie sieci neuronowe (CNN, RNN, Transformer), transfer learning i zasady odpowiedzialnej AI. [K_W22]

Umiejętności

- Student potrafi zastosować aparat matematyczny (rachunek różniczkowy, algebrę liniową, statystykę) do implementacji i analizy algorytmów uczenia maszynowego w Pythonie (scikit-learn, PyTorch/TensorFlow). [K_U07]
- Student potrafi zdiagnozować problem z obszaru sztucznej inteligencji, zaprojektować pipeline danych, wytrenować, ocenić i zoptymalizować model ML/DL na danych rzeczywistych. [K_U29]

Kompetencje społeczne

- Student jest gotów do zastosowania sztucznej inteligencji na rzecz rozwiązywania problemów naukowych i społecznych z uwzględnieniem zasad etycznej AI. [K_K01]

- Student jest gotów do samodzielnego śledzenia postępów w dziedzinie ML/AI i adaptowania nowych metod w praktyce inżynierskiej. [K_K03]

7. Kryteria oceny

- wyklad
- cwiczenia_laboratorium

8. Metody dydaktyczne

wyklad:

- wykład z prezentacją multimedialną
- wykład z prezentacją oprogramowania

cwiczenia_laboratorium:

- rozwiązywanie zadań
- studia przypadków z bazy studiów przypadków opracowanych przez firmy MŚP lub będące efektem staży
- warsztaty

9. Literatura

Podstawowa:

- Daniel T. Larose „Metody i modele eksploracji danych", PWN 2022
- Aurélien Géron, „Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow", Helion 2020
- Robert Johansson „Matematyczny Python. Obliczenia naukowe i analiza danych z użyciem NumPy, SciPy i Matplotlib", Helion 2021
- Sebastian Raschka, Vahid Mirjalili „Python. Machine learning i deep learning. Biblioteki scikit-learn i TensorFlow 2", Helion 2021
- Aileen Nielsen, „Szeregi czasowe. Praktyczna analiza i predykcja z wykorzystaniem statystyki i uczenia maszynowego", Helion 2020

Uzupełniająca:

- Joel Grus, „Data science od podstaw. Analiza danych w Pythonie", Helion 2020
- Dokumentacja pakietów Keras i Tensorflow